

# Mercado financiero a través de redes multicapa: Análisis de robustez del índice S&P100

García D., Guerrero A.

## Resumen

Se extrajeron las series de tiempo de las acciones del índice S&P100 a lo largo de cinco trimestres financieros. Se siguió un algoritmo para construir una red temporal, en la que cada capa es un trimestre financiero y cuyos nodos son las acciones que conforman el índice. Los nodos formaron enlaces de acuerdo a la relación de causalidad entre ellas, y el peso de los enlaces es el nivel de cointegración entre las series de tiempo. Finalmente, se utilizaron métricas de redes multicapa para identificar los nodos que influyen sobre el mercado, *jugadores influencers*, los nodos influenciados por el mercado *jugadores vulnerables* y los nodos que evitan que un colapso en un sector se propague a todo el mercado, *guardianes*.

## 1. Introducción

Las redes complejas son representaciones matemáticas de sistemas compuestos por elementos interactuantes, donde los nodos representan unidades discretas y los enlaces capturan sus interacciones por pares. Estas estructuras exhiben propiedades topológicas no triviales (como distribuciones de grado libres de escala o fenómenos de mundo pequeño) que las distinguen de grafos puramente aleatorios. Su análisis revela cómo el comportamiento macroscópico del sistema emerge de patrones microscópicos de interacción, regidos por principios de dinámica no lineal y estadística.

El estudio de estas redes resulta particularmente relevante al proporcionar un marco teórico para analizar patrones universales de organización en sistemas altamente interconectados. A diferencia de los enfoques reduccionistas tradicionales (que examinan componentes aislados), permiten caracterizar rigurosamente cómo la estructura de interacciones entre elementos da lugar a propiedades emergentes, dinámicas colectivas y comportamientos no intuitivos.

En este contexto, nuestro trabajo emplea redes complejas temporales para examinar las interconexiones dinámicas entre los componentes del índice S&P100, representativo de las principales empresas estadounidenses. Este enfoque nuevo supera las limitaciones de los análisis tradicionales al modelar explícitamente la evolución temporal de las relaciones financieras mediante un marco de redes "dinámicas".

En cuanto al estado de este enfoque con redes complejas, la última década ha presenciado un crecimiento sustancial en investigaciones que emplean sistemas complejos y particularmente redes complejas basadas en series temporales para modelar sistemas dinámicos [1]. Los enfoques recientes han abordado la dimensión temporal mediante consolidación de conexiones entre nodos y enlaces, incluso disponiendo de datos secuenciales detallados [2].

Como evidencia de esta tendencia, destacan los trabajos de Karimi y Holme [3] con modelos de umbral en redes temporales para fenómenos de influencia social, así como los estudios de Deng y colaboradores [4] que revelaron patrones estructurados en entornos comerciales. Complementariamente, Flores y Romance [5] establecieron la importancia de los nodos centrales en el análisis de redes.

En el ámbito de aplicaciones específicas, Everett y su equipo [6] implementaron técnicas bimodales en redes sociales, mientras Li y colegas [7] aplicaron algoritmos de árboles de decisión para identificar atributos nodales. La transposición de estas metodologías al análisis financiero ha ganado relevancia reciente, con contribuciones como el algoritmo de difusión temporal inversa de Huang y colaboradores [8], o los marcos de correlaciones dinámicas desarrollados por Zhao y su equipo [9].

No obstante estos avances, persiste una brecha significativa: mientras los estudios existentes han aportado valiosos insights sobre niveles críticos de volatilidad, han dejado sin examinar los mecanismos estructurales subyacentes que gobiernan la propagación del riesgo. Esta limitación se hace más evidente al contrastar con enfoques tradicionales de análisis bursátil, que se centran en dimensiones como las interrelaciones sectoriales [10], fluctuaciones de volatilidad [11], o restricciones institucionales [12].

Paralelamente, investigaciones recientes han incorporado variables adicionales como riesgos tecnológicos y factores sociopolíticos. Destacan en este ámbito los trabajos de Apergis [13] sobre el impacto de la incertidumbre política en EE.UU., y los estudios de Tsai [14] acerca de la propagación transnacional de riesgos. Desde una perspectiva sociocultural, Cao et al. [15] y Li et al. [16] han establecido correlaciones significativas entre capital social y vulnerabilidades bursátiles en el mercado chino.

El objetivo central de este proyecto radica en analizar la estructura dinámica del mercado accionario del S&P 100 mediante redes complejas temporales, identificando patrones de interconexión, nodos críticos (jugadores clave, gatekeepers) y su relación con la estabilidad financiera. Buscamos emplear un modelo que capture las relaciones evolutivas entre acciones mediante redes temporales, cuyas métricas permitan detectar riesgos sistémicos basados en topología de red y evaluar vulnerabilidades mediante pruebas de robustez.

La relevancia de este enfoque multidimensional reside en su capacidad para proporcionar una visión sistémica del mercado, superando las limitaciones de análisis tradicionales centrados en componentes aislados. Al ofrecer herramientas cuantitativas para la gestión de riesgos en mercados interconectados, este marco metodológico

representa un avance significativo para la toma de decisiones informadas en entornos financieros caracterizados por su creciente complejidad y dinamismo.

## 2. Antecedentes

El riesgo y estabilidad de los mercados financieros se ha analizado desde distintas perspectivas. [13] evaluó el efecto de los riesgos políticos y tecnológicos, así como la incertidumbre de la política económica, sobre los retornos de las acciones en el mercado estadounidense. [16] señaló la correlación entre el riesgo de la caída en el precio de acciones y la confianza social del mercado. Se llevó a cabo un análisis en [17] sobre el riesgo de que las empresas tuvieran problemas financieros en 38 países durante 20 años, concluyendo que el riesgo era mayor en acciones de bajo valor de países desarrollados.

Las investigaciones mencionadas anteriormente utilizan medidas y conceptos clásicos de teoría del riesgo y series de tiempo, como el modelo VAR (*Value at Risk*) y el modelo GARCH (*Generalized Autoregressive Conditional Heteroscedasticity*). Estos artículos se enfocan en el rendimiento de las acciones o la correlación con las decisiones político-económicas y métricas macroeconómicas para explicar el riesgo anormal de dificultades financieras (*financial distress*), el cual es un riesgo inesperado de dificultades económicas para una compañía; pero ninguno estudia los factores particulares que capturan dicho riesgo en las acciones, dificultando predecir la posibilidad de que una empresa o un sector industrial entero entre en dificultades financieras.

También se ha analizado distintos aspectos de mercados financieros utilizando redes complejas. Por ejemplo, [9] logra caracterizar la estructura compleja del mercado financiero, modelando su evolución a través de redes temporales y evaluando su estabilidad mediante un análisis de la estructura topológica. Lo que les ayuda, junto con métricas de redes temporales, a seleccionar acciones para la optimización de un portafolio, maximizando la ganancia y minimizando el riesgo.

En [18] transforman un mercado financiero en una red compleja, en la que los nodos son valores (acciones, deudas o derivados financieros) y los enlaces son las correlaciones de retorno entre los distintos valores. Concluyeron que existe una relación negativa entre la centralidad de los valores y sus pesos óptimos en un portafolio basado en la teoría de Markowitz, es decir, que los portafolios óptimos están conformados por valores con baja centralidad, pues los de alta centralidad suelen ser acciones antiguas o de gran capitalización, pero también las hay más baratas y riesgosas.

En el artículo [19], analizaron la evolución temporal de las relaciones entre 30 índices bursátiles globales y 145 coreanos a lo largo de 13 años, crearon una red en la que cada nodo es un índice y los enlaces indican la similitud en retornos. Encontraron que los índices globales tenían un comportamiento más parecido entre ellos a medida que el tiempo avanzaba, mientras que los índices coreanos no seguían una misma tendencia a excepción de momentos de crisis. Analizando la topología de redes umbral construidas a lo largo de distintas

ventanas temporales, encontraron que en momentos de crisis financieras, la estructura de la red no cambia de manera gradual; en su lugar, cambia de manera abrupta.

## 2.1. Objetivos:

1. Obtener las series de tiempo de las acciones del índice S&P100.
2. Analizar la estacionariedad las series de tiempo mediante el *ADF test*.
3. Emplear el *Granger causality test* para comprobar que acciones tienen una acción causal sobre el precio de otras.
4. Calcular el coeficiente de cointegración mediante *Engle Granger*.
5. Generar una red multicapa para analizar la evolución de las relaciones del mercado financiero.
6. Analizar la red generada mediante métricas de redes multicapa para encontrar nodos principales, vulnerables y porteros.

## 3. Marco Teórico

Un *activo financiero* es un título o anotación contable que otorga a su comprador el derecho a recibir un ingreso futuro por parte del vendedor. Son emitidos por una entidad económica (como empresas y gobiernos) y acreditan la titularidad de ciertos derechos económicos. Los activos financieros tienen las características:

- **Liquidez:** La capacidad de convertir el activo en efectivo sin sufrir pérdidas.
- **Riesgo:** La probabilidad de que el vendedor no cumpla con su compromiso y se calcula en función de las garantías que aporte y su solvencia. A mayor riesgo, mayor rentabilidad.
- **Rentabilidad:** El interés que recibe el comprador del activo en contraprestación al riesgo que asume.

Los activos pueden ser de renta fija o renta variable. La *renta fija* son activos financieros emitidos por empresas, que se comprometen a devolver el dinero prestado en un plazo fijo adicional a una rentabilidad acordada previamente. Por otro lado, los activos de *renta variable* no garantizan la recuperación del dinero invertido ni alguna rentabilidad.

Las *acciones* son títulos representativos de una parte del capital social de una sociedad anónima; se negocian en los mercados bursátiles. Se puede ganar dinero vendiéndolas a un precio mayor al de compra, o a través del reparto de *dividendos* que realizan las sociedades anónimas a sus accionistas.

Los *índices bursátiles* internacionales son un conjunto de acciones. Se calculan como la media (simple o ponderada de acuerdo a cierta característica) de precios de un número de acciones seleccionadas pertenecientes

a un mercado o un sector determinado. Su rendimiento permite conocer la evolución y tendencia de la parte del mercado a la que representan.

El índice *Standard & Poor's 500* se basa en la capitalización bursátil de 500 empresas que poseen acciones que cotizan en las bolsas NYSE o NASDAQ, y captura aproximadamente el 80 % de toda la capitalización de mercado en Estados Unidos. Las empresas que componen el S&P 500 son seleccionadas por un comité, basándose en ocho criterios primarios: capitalización bursátil, liquidez, domicilio, capital flotante, clasificación del sector, viabilidad financiera, periodo de tiempo durante el cual ha cotizado en bolsa y bolsa de valores. El índice está ponderado de acuerdo a la capitalización de cada empresa. Así, empresas con mayor capital flotante (precio de una acción  $\times$  cantidad de acciones que no pertenecen a fundadores), tendrán mayor peso en el índice. El *Standard & Poor's 100* es un subconjunto con las 100 empresas estadounidenses con mayor capitalización bursátil.

Una *serie de tiempo* es una secuencia ordenada de observaciones  $\{x_t\}_{t \in T}$  de una variable aleatoria  $X_t$ , donde  $T \subseteq \mathbb{R}$  representa el dominio temporal (discreto o continuo). Formalmente, se modela como una realización de un proceso estocástico  $\{X_t\}_{t \in T}$  en un espacio de probabilidad  $(\Omega, \mathcal{F}, P)$ , donde:

- Para cada  $t \in T$ ,  $X_t : \Omega \rightarrow \mathbb{R}^d$  es una variable aleatoria (univariante si  $d = 1$ , multivariante si  $d > 1$ ).
- Para cada  $\omega \in \Omega$ , la trayectoria  $\{X_t(\omega)\}_{t \in T}$  es una serie temporal observada.

Las series de tiempo capturan la evolución de fenómenos dinámicos, permitiendo analizar tendencias, estacionalidad o patrones ocultos.

Una serie de tiempo  $\{X_t\}$  es *estacionaria* si sus propiedades estadísticas son invariantes en el tiempo. Formalmente, cumple:

- **Media constante:**  $\mathbb{E}[X_t] = \mu \quad \forall t \in T$ .
- **Varianza constante:**  $\text{Var}(X_t) = \mathbb{E}[(X_t - \mu)^2] = \sigma^2 < \infty \quad \forall t \in T$ .
- **Autocovarianza dependiente solo del lag  $h$ :**  $\text{Cov}(X_t, X_{t+h}) = \gamma(h) \quad \forall t, h \in T$  donde  $\gamma(0) = \sigma^2$  representa la varianza y  $\gamma(1)$  la autocovarianza con un retardo de un periodo.

En modelos financieros, la estacionariedad se logra frecuentemente aplicando diferencias a series no estacionarias, transformándolas en  $I(0)$ .

La *prueba Augmented Dickey-Fuller (ADF)* es un test estadístico que verifica la presencia de raíz unitaria ( $H_0$ ) en una serie de tiempo, determinando si es no estacionaria ( $I(0)$ ). Extiende el test Dickey-Fuller básico incorporando retardos de las diferencias para controlar correlaciones seriales. El modelo de regresión es:

$$\Delta y_t = \alpha + \beta t + \gamma y_{t-1} + \sum_{i=1}^p \delta_i \Delta y_{t-i} + \epsilon_t$$

donde:

- $\Delta y_t = y_t - y_{t-1}$  (primera diferencia),
- $\alpha$ : término constante,
- $\beta t$ : tendencia temporal,
- $\gamma$ : coeficiente crítico ( $H_0 : \gamma = 0$ ),
- $\delta_i$ : coeficientes de  $p$  rezagos,
- $\epsilon_t \sim \text{IID}(0, \sigma^2)$  (ruido).

La prueba contrasta dos hipótesis:

1.  $H_0: \gamma = 0$  (raíz unitaria  $\Rightarrow$  no estacionariedad)
2.  $H_1: \gamma < 0$  (la serie es estacionaria)

El estadístico ADF es el valor  $t$  para  $\gamma$ :

$$\text{ADF} = \frac{\hat{\gamma}}{\text{SE}(\hat{\gamma})}$$

Comparado con valores críticos de Dickey-Fuller. Si  $\text{ADF} < \text{valor crítico}$ , se rechaza  $H_0$ , concluyendo que la serie es estacionaria. El parámetro clave es el número de rezagos ( $p$ ), se usa para eliminar autocorrelación residual.

La *test de causalidad de Granger* evalúa si  $X_t$  ayuda a predecir  $Y_t$  mediante un contraste de modelos anidados:

$$Y_t = \alpha + \sum_{i=1}^p \beta_i Y_{t-i} + \sum_{j=1}^q \gamma_j X_{t-j} + u_t$$

La prueba contrasta dos hipótesis:

- $H_0: \gamma_j = 0 \forall j$  (Los valores pasados de  $X$  no ayudan a predecir los valores de  $Y$  más allá de lo que ya explica la serie de  $Y$ ).
- $H_1: \gamma_j \neq 0$  ( $X_t$  ayuda a predecir los valores de  $Y_t$ ).

Se rechaza  $H_0$  si  $F > F_{\text{crítico}}$  (o  $p\text{-value} < \alpha$ ).

La *prueba de cointegración de Engle-Granger* evalúa si existe una relación de equilibrio a largo plazo entre dos series no estacionarias integradas del mismo orden ( $I(1)$ ). Consta de dos etapas:

1. Estimación de la relación de largo plazo: Si las series  $X_t$  y  $Y_t$  son no estacionarias pero se vuelven estacionarias tras aplicar la primera diferencia (i.e., son  $I(1)$ ), se estima el siguiente modelo de mínimos cuadrados ordinarios:

$$Y_t = \omega_0 + \omega_1 X_t + \epsilon_t$$

donde  $\omega_0$  y  $\omega_1$  son parámetros estimados, y  $\varepsilon_t$  es el residuo o error de la regresión. El residuo estimado se calcula como:

$$e_t = Y_t - (\hat{\omega}_0 + \hat{\omega}_1 X_t)$$

2. Prueba de estacionariedad de los residuos: Se verifica si la secuencia de residuos  $\{e_t\}$  es estacionaria Dickey-Fuller aumentada (ADF) sobre  $\Delta e_t$ :

$$\Delta e_t = \eta e_{t-1} + \sum_{i=1}^m \rho_i \Delta e_{t-i} + \varepsilon_t$$

donde:

- $\Delta e_t = e_t - e_{t-1}$  es la primera diferencia de los residuos,
- $\eta$  es el coeficiente de  $e_{t-1}$  que se evalúa con la hipótesis  $H_0 : \eta = 0$  (raíz unitaria en residuos),
- $\rho_i$  son los coeficientes de las diferencias rezagadas de los residuos,
- $\varepsilon_t$  es un término de error con media cero y varianza constante.

Si los residuos  $\{e_t\}$  son estacionarios ( $I(0)$ ), entonces  $X_t$  y  $Y_t$  están cointegrados, es decir, existe una relación de equilibrio de largo plazo entre ambas variables.

Una *red compleja multicapa* con M capas se define como  $\mathcal{M} = (G, C)$  en donde  $G = \{G_\alpha : \alpha \in \{1, \dots, M\}\}$  es una familia de redes, las cuales pueden ser dirigidas o no y con pesos en los enlaces o sin ellos y  $G_\alpha = (X_\alpha, E_\alpha)$  es una *red monocapa*, el conjunto  $C = \{E_{\alpha\beta} \subseteq X_\alpha \times X_\beta : \alpha, \beta \in \{1, \dots, M\} \text{ con } \alpha \neq \beta\}$

Una *red temporal*  $(G(t))_{t=1}^T$  es una red cuyos conjuntos de nodos y enlaces varían de acuerdo al tiempo en el que esten. Se puede ver como una red multicapa considerando al conjunto de capas  $\{G_1, \dots, G_T\}$  y  $E_{\alpha\beta} = \emptyset$  si  $\beta \neq \alpha + 1$  y  $E_{\alpha, \alpha+1} = \{(x, x); x \in X_\alpha \cap X_{\alpha+1}\}$ .

La *centralidad de grado* de un nodo  $i \in X$  de una red multicapa  $\mathcal{M} = (g, C)$  es  $\bar{k}_i = (k_i^{[1]}, \dots, k_i^{[M]})$ , con  $k_i^{[\alpha]}$  la centralidad de grado del nodo  $i$  en la capa  $\alpha$ , es decir,  $k_i^{[\alpha]} = \sum_j a_{ij}^{[\alpha]}$  con  $a_{ij}$  la  $ij$ -ésima entrada de la matriz de adyacencia de la red en la capa  $\alpha$ .

La *centralidad de superposición* de un nodo  $i \in X_\alpha$  para alguna  $\alpha \in 1, \dots, M$  es  $o_i = \sum_\alpha^M k_i^{[\alpha]}$ , o visto de otra forma,  $o_i = \|k_i\|_1$  (se puede sustituir la norma-1 por combinaciones convexas de los  $k_i^{[j]} \forall j \in 1, \dots, M$  o cualquier otra norma de  $k_i$ ).

La *centralidad de in-grado* de un nodo  $i \in X$  en una red multicapa dirigida  $\mathcal{M} = (g, C)$  se define como  $\bar{k}_i^{\text{in}} = (k_i^{\text{in}, [1]}, \dots, k_i^{\text{in}, [M]})$ , donde  $k_i^{\text{in}, [\alpha]}$  representa el número de enlaces que llegan al nodo  $i$  en la capa  $\alpha$ , es decir,

$$k_i^{\text{in}, [\alpha]} = \sum_j a_{ji}^{[\alpha]},$$

donde  $a_{ji}^{[\alpha]}$  es la entrada  $ji$  de la matriz de adyacencia dirigida en la capa  $\alpha$ .

La *centralidad de ex-grado* de un nodo  $i \in X$  se define como  $\overline{k}_i^{\text{ex}} = \left(k_i^{[\text{ex},1]}, \dots, k_i^{[\text{ex},M]}\right)$ , donde  $k_i^{[\text{ex},\alpha]}$  representa el número de enlaces que salen desde el nodo  $i$  en la capa  $\alpha$ , es decir,

$$k_i^{[\text{ex},\alpha]} = \sum_j a_{ij}^{[\alpha]}.$$

La *centralidad intermedia* (*betweenness centrality*) de un nodo  $i$  en una red compleja dirigida o no dirigida se define como:

$$b_i = \sum_{s \neq i \neq t} \frac{\sigma_{st}(i)}{\sigma_{st}},$$

donde:

- $\sigma_{st}$  es el número total de caminos geodésicos (más cortos) entre los nodos  $s$  y  $t$ ,
- $\sigma_{st}(i)$  es el número de esos caminos que pasan por el nodo  $i$ .

Esta medida captura la influencia de un nodo en la comunicación dentro de la red, al cuantificar cuántas veces actúa como intermediario en las rutas más cortas entre otros pares de nodos.

En una red multicapa  $\mathcal{M} = (g, C)$  con  $M$  capas, la *centralidad intermedia multicapa* de un nodo  $i \in X$  se representa como el vector:

$$\overline{b}_i = \left(b_i^{[1]}, \dots, b_i^{[M]}\right),$$

donde  $b_i^{[\alpha]}$  es la centralidad intermedia del nodo  $i$  calculada únicamente en la capa  $\alpha$  de la red.

## 4. Metodología

Se obtuvieron las series de tiempo de las acciones que forman parte del índice S&P100 usando la biblioteca *yfinance* de Python. Se descargaron los datos del día, ticker de la acción, precio de apertura, precio de cierre, precio mínimo, precio máximo y precio de cierre ajustado desde el 2024-01-01 hasta el 2025-03-31. Se dividieron las series de tiempo en trimestres financieros:

1. Q1: del 2024-01-01 al 2024-03-31
2. Q2: del 2024-04-01 al 2024-06-30
3. Q3: del 2024-07-01 al 2024-09-30
4. Q4: del 2024-10-01 al 2024-12-31
5. Q5: del 2025-01-01 al 2025-03-31

Se siguió el algoritmo para construir la red propuesto en [20]:



1. Se calcularon los precios logarítmicos  $P_i(t) = \ln(price)_i(t)$  y los retornos logarítmicos  $R_i(t) = P_i(t + 1) - P_i(t)$  de las series de tiempo.
2. Se aplicó la prueba de *Augmented Dickey-Fuller* sobre las series de tiempo de los retornos logarítmicos para conocer el orden de integración de las series de tiempo.
3. Las series que no fueron estacionarias (distintas de  $I(0)$ ) se diferenciaron hasta volverse estacionarias. En este caso, solo hubo series  $I(0)$  y  $I(1)$ .
4. Se realizó la prueba de *Granger causality* entre los retornos logarítmicos  $R_i^k$  y  $R_j^k$  (con  $i \neq j$ ) para cada trimestre financiero  $k$ . Se estableció una relación causal dirigida desde la acción  $i$  hacia la acción  $j$  ( $a_{ij}^k = 1$ ) cuando el valor  $p$  obtenido ( $p_{ij}^k$ ) fue menor que un nivel de significancia  $p^* = 0,05$ . En caso contrario ( $p_{ij}^k \geq p^*$ ) no diremos que no hay una relación ( $a_{ij}^k = 0$ ).
5. Para cada par de acciones  $(i, j)$  tal que  $a_{ij}^k = 1$ , se aplicó la prueba de cointegración de *Engle-Granger* entre las series de precios  $P_i^k$  y  $P_j^k$ . Si se encontró cointegración, se consideró el coeficiente de cointegración  $\omega_{ij}^k$  como el peso de la arista dirigida desde la acción  $i$  hacia la acción  $j$ , lo cual indica la fuerza con la que las fluctuaciones de precios de  $j$  son explicadas por las de  $i$ . Se definió la matriz de adyacencia  $\tilde{a}_{ij}^k$  con:

$$\tilde{a}_{ij}^k = \begin{cases} \omega_{ij}^k, & \text{si } a_{ij}^k = 1 \\ 0, & \text{en otro caso} \end{cases}$$

De este modo, se construyó la matriz de adyacencia ponderada  $A^k = (\tilde{a}_{ij}^k)_{m \times m}$ , la cual es asimétrica con ceros en la diagonal.

6. Se repitieron los pasos anteriores para cada capa de la red.

Finalmente, se utilizaron métricas de redes multicapa para identificar los nodos que influyen sobre el mercado, *jugadores influencers*, los nodos influenciados por el mercado *jugadores vulnerables* y los nodos que evitan que un colapso en un sector se propague a todo el mercado, *jugadores guardianes*.

## 5. Resultados

Se dividieron las series de tiempo en trimestres financieros:

1. Q1: del 2024-01-01 al 2024-03-31
2. Q2: del 2024-04-01 al 2024-06-30
3. Q3: del 2024-07-01 al 2024-09-30
4. Q4: del 2024-10-01 al 2024-12-31
5. Q5: del 2025-01-01 al 2025-03-31



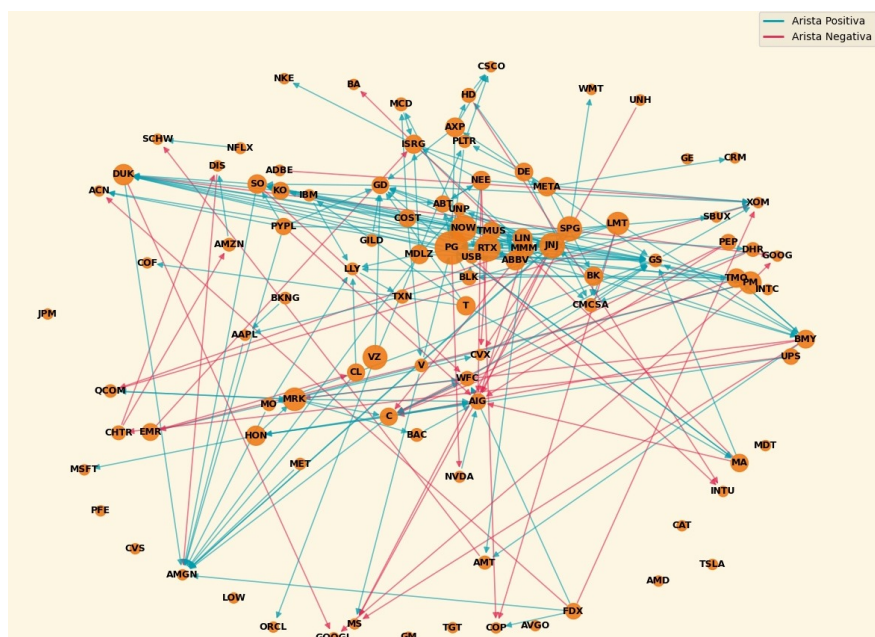


Figura 3: Capa del tercer trimestre (Q3): del 2024-07-01 al 2024-09-30.

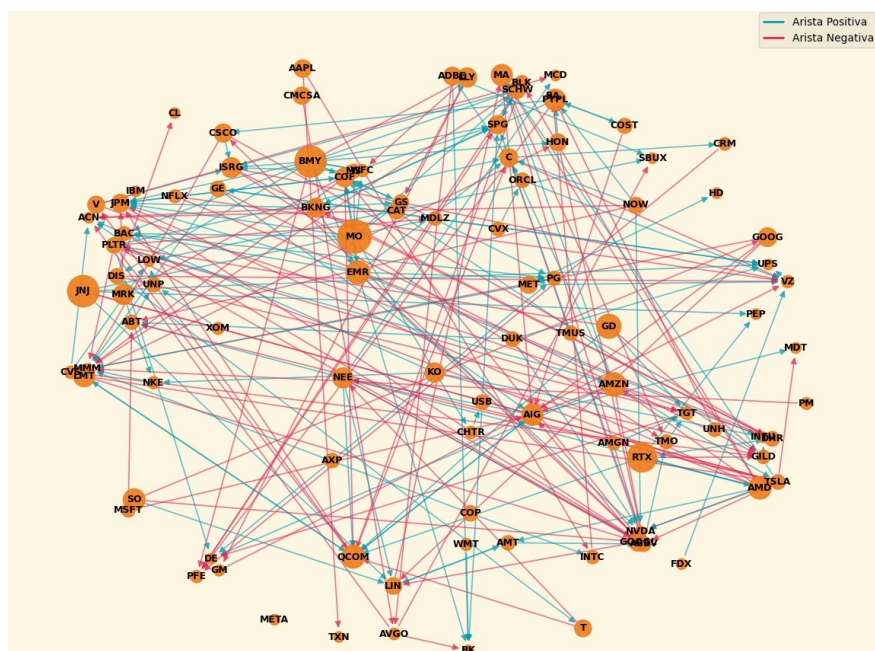


Figura 4: Capa del cuarto trimestre (Q4): del 2024-10-01 al 2024-12-31.

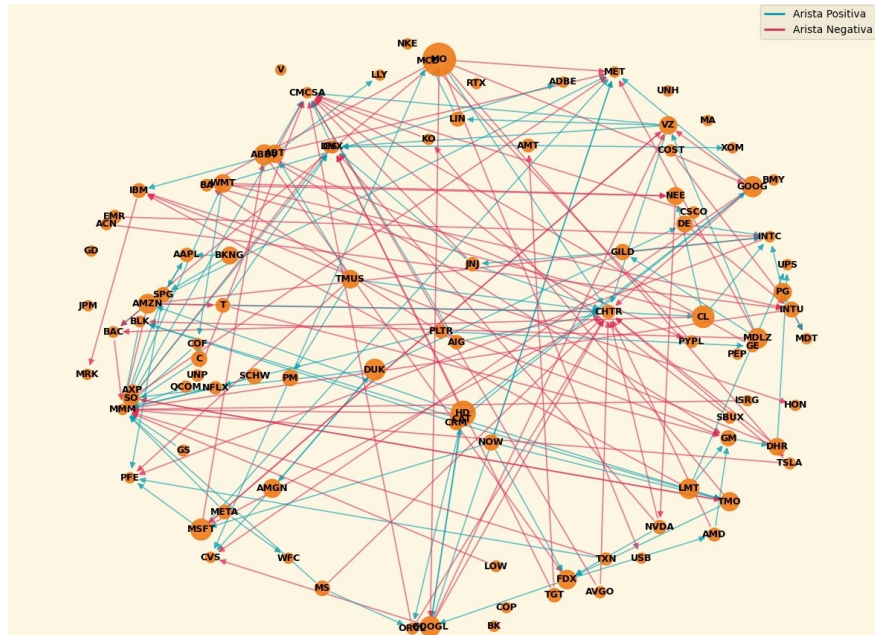


Figura 5: Capa del quinto trimestre (Q5): del 2025-01-01 al 2025-03-31.

Trimestre	Acción	Ingrado
Q1	META (Meta Platforms Inc)	15.1132
	NVDA (NVIDIA Corp)	13.7344
	PLTR (Palantir Technologies Inc)	12.4033
Q2	TXN (Texas Instruments Inc)	11.8155
	TSLA (Tesla Inc)	10.3104
	INTC (Intel Corp)	8.4665
Q3	MMM (3M Co)	5.9905
	DUK (Duke Energy Corp)	5.9871
	ABT (Abbott Laboratories)	4.9576
Q4	TSLA (Tesla Inc)	12.0257
	ABBV (AbbVie Inc)	7.6771
	DHR (Danaher Corp)	7.0123
Q5	CVS (CVS Health Corp)	5.1789
	INTC (Intel Corp)	4.4428
	TSLA (Tesla Inc)	3.8721

Cuadro 1: Acciones más vulnerables por trimestre

Al analizar el mercado desde la mesoescala podemos observar que las acciones más vulnerables son las del sector farmacéutico (CSV, ABT, ABBV) y tecnológico (META, NVDA, TSLA, INTC, DHR). Por lo que en el periodo analizado es recomendable no invertir en dichos sectores, pues el precio de la acción no lo estará determinando las empresas, sino el mercado en general.

Trimestre	Acción	Exgrado
Q1	PG (Procter & Gamble C)	11.9427
	DHR (Danaher Corp)	10.7801
	CVX (Chevron Corp)	10.2746
Q2	BK (Bank of New York Mellon Corp)	11.3191
	LMT (Lockheed Martin Corp)	8.7445
	MO (Altria Group Inc)	8.1870
Q3	PG (Procter & Gamble C)	10.2979
	RTX (Rtx Corp)	5.7982
	NOW (ServiceNow Inc)	5.7905
Q4	MO (Altria Group Inc)	11.2574
	JNJ (Johnson & Johnson)	9.8160
	BMJ (Bristol-Myers Squibb Co)	9.6284
Q5	MO (Altria Group Inc)	9.5673
	HD (Home Depot Inc)	4.8029
	CL (Colgate-Palmolive Co)	3.5659

Cuadro 2: Acciones más influyentes por trimestre

Los sectores que más influencia tienen sobre el mercado financiero y afectan al resto del mercado estadounidense son el sector financiero (por ejemplo, Bank of New York Mellon Corp), el energético (Chevron Corp) y el de defensa (Lockheed Martin Corp, RTX Corp). Además, el sector de consumo básico también muestra relevancia en varios trimestres, representado por empresas como Procter & Gamble, Altria Group Inc y Colgate-Palmolive Co.

Trimestre	Acción	Intermedia
Q1	DIS (Walt Disney Co)	0.0335
	CVX (Chevron Corp)	0.0332
	AAPL (Apple Inc)	0.0311
Q2	INTC (Intel Corp)	0.0249
	LMT (Lockheed Martin Corp)	0.0248
	GOOG (Google, Alphabet Inc Class C)	0.0204
Q3	SO (Southern Co)	0.0613
	PG (Procter & Gamble Co)	0.0567
	LIN (Linde PLC)	0.0492
Q4	QCOM (Qualcomm Inc)	0.1210
	BKNG (Booking Holdings Inc)	0.0751
	COF (Capital One Financial Corp)	0.0711
Q5	FDX (FedEx Corp)	0.0718
	CHTR (Charter Communications Inc)	0.0559
	CL (Colgate-Palmolive Co)	0.0557

Cuadro 3: Acciones portero o guardian por trimestre

Se puede observar entre los nodos que evitan la caída de todo el mercado empresas de sectores tecnológico (Apple Inc., Intel Corp., Google, Qualcomm Inc.), comunicaciones (Walt Disney Co., Charter Communications Inc.), consumo básico (Procter & Gamble, Colgate-Palmolive Co.), energético (Chevron Corp., Southern Co.), y transporte y logística (FedEx Corp.). Estos sectores juegan un papel estabilizador en el mercado, son activos defensivos en periodos de alta volatilidad. Estos sectores reflejan una economía saludable, pues en periodos de estabilidad económica se piden mas paquetes (transporte y logística), la gente tiene dinero para

pagar por entretenimiento (comunicaciones y consumo básico).

Trimestre	Densidad	Clustering
Q1	0.0169	0.1064
Q2	0.0192	0.1302
Q3	0.0210	0.1199
Q4	0.0243	0.1076
Q5	0.0176	0.0915

Cuadro 4: Densidad y coeficiente de clustering por trimestre

La densidad es baja a lo largo de todas las capas, lo que indica que la variación de los precios en las acciones está débilmente conectadas entre sí, lo que refleja que no hay interdependencia significativa entre acciones en el periodo analizado.

El coeficiente de clustering nos dice qué tan probable es que si una acción A influye en el precio de una acción B y la acción B influye sobre el precio de C, entonces la acción A influye en el precio de C. Los valores mostrados son bajos, pero con el contexto de ser una red financiera muestra que es un valor moderado. Lo más probable es que se hagan *clusters* por sector de mercado (salud con salud, tecnología con tecnología, etc).

## 6. Conclusiones

El uso de redes complejas temporales, combinado con análisis de series de tiempo, son una herramienta avanzada para detectar patrones ocultos y analizar de mejor forma sistemas complejos. Se analizó el mercado financiero de E.U.A. utilizando las acciones que conforman el S&P100; se detectaron patrones y correlaciones de precio entre distintas acciones y sectores del mercado bursátil utilizando pruebas de causalidad (*Granger causality test*) y de cointegración (*Engle-Granger cointegration test*).

Mediante métricas de redes multicapa se detectaron las acciones y sectores que más influencia tienen sobre el mercado (financieras, energéticas y de defensa), los sectores cuyas acciones no dependían de ellas, sino del resto del mercado (farmacéuticas y tecnológicas) y, finalmente, las acciones que tienen la capacidad de prevenir o frenar caídas del mercado (consumo, tecnológicas y comunicaciones).

Al comparar los resultados obtenidos en el trabajo con el realizado por Su, Q, et. al. [20], en donde hay mayor presencia de cointegración entre las acciones, se deja como investigación futura analizar si es debido a que utilizaron un mayor número de acciones (300), o si es porque en China el gobierno tiene participación en la mayoría de empresas y hay mayor transparencia de las decisiones que toman.

Como trabajo complementario se podrían analizar más trimestres financieros, o utilizar una escala distinta (por ejemplo, anual), para ver si los sectores cambian. También puede ampliarse la investigación si se imple-



mentan análisis de noticias en los periodos deseados, utilizando *Natural Language Processing* para tener un contexto mas amplio de las noticias para cada sector.

## Referencias

1. Zou, Y., Donner, R. V., Marwan, N., Donges, J. F. y Kurths, J. Complex network approaches to nonlinear time series analysis. *Physics Reports* **787**. In press (2019).
2. Holme, P. y Saramäki, J. Temporal networks. *Physics Reports* **519**, 97-125 (2012).
3. Karimi, F. y Holme, P. Threshold model of cascades in empirical temporal networks. *Physica A: Statistical Mechanics and its Applications* **392**, 3476-3483 (2013).
4. Deng, S., Qiu, L., Yang, Y. y Yang, H. A diffusion perspective on temporal networks: a case study on a supermarket. *Physica A: Statistical Mechanics and its Applications* **441**, 62-68 (2016).
5. Flores, J. y Romance, M. On eigenvector-like centralities for temporal networks: discrete vs. continuous time scales. *Journal of Computational and Applied Mathematics* **330**, 1041-1051 (2018).
6. Everett, M. G., Broccatelli, C., Borgatti, S. P. y Koskinen, J. Measuring knowledge and experience in two mode temporal networks. *Social Networks* **55**, 63-73 (2018).
7. Li, T. *et al.* Exploring the transition behavior of nodes in temporal networks based on dynamic community detection. *Future Generation Computer Systems* **107**, 458-468 (2020).
8. Huang, Q., Zhao, C., Zhang, X. y Yi, D. Locating the source of spreading in temporal networks. *Physica A: Statistical Mechanics and its Applications* **468**, 434-444 (2017).
9. Zhao, L. *et al.* Stock market as temporal network. *Physica A: Statistical Mechanics and its Applications* **506**, 1104-1112 (2018).
10. Watts, D. J. y Strogatz, S. H. Collective dynamics of “small-world” networks. *Nature* **393**, 440-442 (1998).
11. Topaloglou, N., Vladimirov, H. y Zenios, S. A. Integrated dynamic models for hedging international portfolio risks. *European Journal of Operational Research* **285**, 48-65 (2020).
12. Campbell, J. Y., Hilscher, J. y Szilagyi, J. Predicting financial distress and the performance of distressed stocks. *CFA Digest* **9**, 14-34 (2011).
13. Apergis, N. Policy risks, technological risks and stock returns: New evidence from the US stock market. *Economic Modelling* **51**, 359-365 (2015).
14. Tsai, I.-C. The source of global stock market risk: a viewpoint of economic policy uncertainty. *Economic Modelling* **60**, 122-131 (2017).
15. Cao, C., Xia, C. y Chan, K. Social trust and stock price crash risk: evidence from China. *International Review of Economics & Finance* **46**, 148-165 (2016).

16. Li, X., Wang, S. S. y Wang, X. Trust and stock price crash risk: Evidence from China. *Journal of Banking & Finance* **76**, 74-91 (2017).
17. Gao, P., Parsons, C. A. y Shen, J. Global relation between financial distress and equity returns. *The Review of Financial Studies* **31**, 239-277 (2018).
18. Peralta, G. y Zareei, A. A network approach to portfolio selection. *Journal of Empirical Finance* **38**, 157-180 (2016).
19. Nobi, A., Lee, S., Kim, D. H. y Lee. Correlation and network topologies in global and local stock indices.
20. Su, Q., Tu, L., Wang, X. y Rong, H. Construction and robustness of directed-weighted financial stock networks via meso-scales. *Physica A: Statistical Mechanics and its Applications* **605**, 127955 (2022).